

Построение оптимальной модели декодирования сигналов при моделировании нейрокомпьютерного интерфейса

Крюков М.А., Шеменев А.А., Латыпова Г.Р.,
Бородулин И.С., Борзилов А.В

Московский физико-технический институт

Курс: Машинное обучение
Научный руководитель: Стрижов В.В.
Консультант: Исаченко Р.
Осень 2018

Цель исследования

Построить оптимальную систему декодирования сигнала электрокортикограммы (ECoG) с целью прогнозирования амплитуды сжатия и разжатия фаланг пальцев руки.

Проблема

Сигналы ECoG с нескольких электродов коррелированы, что приводит к переобучению моделей


Причины корреляции:

- Одинаковая природа сигналов
- Зависимость переменных

Решение

Использование алгоритмов снижения размерности входных и **выходных** данных

Исходные данные



- Nanying Liang and Laurent Bougrain. Decoding finger flexion from band-specific ECoG signals in humans. *Frontiers in Neuroprosthetics*, June 2012
- Anastasia Motrenko and Vadim Strijov. Multi-way Feature Selection for ECoG-based Brain-Computer Interface. *Expert Systems with Applications*, July 2018
- Kai J. Miller and Gerwin Schalk. Prediction of Finger Flexion. 4th *Brain-Computer Interface Data Competition*, June 2008
- Rémi Flamary and Alain Rakotomamonjy. Decoding finger movements from ECoG signals using switching linear models. *Frontiers in Neuroscience*, March 2012

Постановка задачи

Данные собираются в образец (\mathbf{D}, \mathbf{Y})

$$\mathbf{D} \in \mathbb{R}^{M \times T \times F \times N_{ch}},$$

$$\mathbf{D}_{(m,t,f,n_{ch})} = \mathbf{X}_m,$$

$$\mathbf{Y} = [\mathbf{y}_1^T, \dots, \mathbf{y}_M^T]^T,$$

где наблюдение соответствует комбинации амплитуд сжатия $\mathbf{y}_m = \mathbf{y}(t_m)$ и матрице $\mathbf{X}_m \in \mathbb{R}^{T \times F \times N_{ch}}$.

Линейная регрессия:

$$\hat{\mathbf{y}}_m = \hat{\mathbf{w}} \mathbf{X}_m$$

$\hat{\mathbf{w}}$ - вектор весов, минимизирующий квадрат суммы остатков:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2$$

где $\hat{\mathbf{Y}} = [\hat{\mathbf{y}}_1^T, \dots, \hat{\mathbf{y}}_M^T]^T$.

Базовый алгоритм – метод частичных наименьших квадратов (PLS).

$$y^{(0)} := \bar{y}$$

$$x_j^{(0)} := x_j \quad (j = 1, 2, \dots, p)$$

для $m = 1, \dots, p$

$$z_m := \sum_{j=1}^p \phi_{mj} x_j^{(m-1)}, \text{ где } \phi_{mj} = \langle y, x_j^{(m-1)} \rangle$$

$$y^{(m)} := y^{(m-1)} + \Theta_m z_m, \text{ где } \Theta_m = \frac{\langle y, z_m \rangle}{\langle z_m, z_m \rangle}$$

$$x_j^{(m)} := x_j^{(m-1)} - \frac{\langle x_j^{(m-1)}, z_m \rangle}{\langle z_m, z_m \rangle} z_m \quad (j = 1, \dots, p)$$

$$\text{Возвратить } y^{(m)} \quad (m = 1, \dots, p) \text{ и } w_{jm}^{pls} = \sum_{l=1}^m \phi_{lj} \Theta_l$$

$$\text{На выходе алгоритма: } y^{(m)} = \sum_{j=1}^p w_{jm}^{pls} x_j \quad (m = 1, \dots, p)$$

- Предобработка данных:
 - спектральный анализ (autoregressive spectral estimation)
 - wavelet-преобразование
 - AM - переход к частичному представлению
- Отбор признаков и снижение размерности признакового пространства:
 - PLS, PCA
 - wrapper feature selection
- Модель
 - регрессия
 - CNN + LSTM


Проверить эффективность последовательного применения wavelet-преобразования и PLS к данным 4th Brain-Computer Interface Data Competition.

Данные

- Массивом платиновых электродов были сняты сигналы ECoG, с помощью полосового фильтра были выделены частоты 0,15 - 200 Гц
- Были зарегистрированы амплитуды сжатия пальцев участников эксперимента

Датасет состоит из многомерного временного ряда

Результаты



Коэффициент детерминации $R^2 = 0.57$

Результаты

- Рассмотрена задача декодирования сигнала ECoG
- Проведен базовый эксперимент

Дальнейшая работа

В будущих исследованиях планируется проверить предложенные гипотезы.

- спектральный анализ (autoregressive spectral estimation)
- AM - переход к частотному представлению
- PCA
- wrapper feature selection
- CNN + LSTM